谢雨豪

大模型高效推理 | KV Cache 量化 | GPU 内核优化

+86 13968074414 | yuhaoxie1999@gmail.com | GitHub: wsxhjnb1 | LinkedIn: yuhao-xie

计算机工程博士在读，研究方向为大模型高效推理与低比特 KV Cache 量化。**EMNLP 2026 主会一作论文已接收**，具备 CUDA 量化内核开发与大模型推理引擎集成经验。

教育背景

中佛罗里达大学（UCF） | 计算机工程博士在读 2023.08 – 2027.08（预计）

佛罗里达大学（UF） | 电气与计算机工程硕士 2021.08 – 2023.05

杭州电子科技大学 | 电气与计算机工程学士 2017.09 – 2021.06

学术论文

Yuhao Xie, Mingjie Lin.

Beyond: Better-than-Full-Precision KV Caches via Learnable Non-Uniform Quantization as Implicit Regularization.

EMNLP 2026, main conference. [论文全文] [开源代码] [项目主页]

研究主题：可学习非均匀 KV Cache 量化与隐式正则化。

大模型研究与工程经历

同花顺（Hithink RoyalFlush Information Network） 2024.05 – 2024.08

大语言模型研究实习生 中国，浙江

- 开发大模型张量量化与反量化 **CUDA 内核**，相较 PyTorch 实现，执行耗时降低 **90%**；集成至公司大模型推理引擎，支持 **FlashAttention 与分页 KV Cache 计算**。
- 实现 **2-bit KV Cache 量化**，对 Key、Value 分别沿序列长度与头维度分组；在**单张 NVIDIA A10、公司 7B 金融大模型**上，GPU 显存占用降低 **50%**，吞吐量达到原来的 **8 倍**。
- 基于内部评测调整量化分组大小与残差长度，量化后保留原模型 **99.3% 的准确率**。

代表性系统项目

量化 KV Cache 的融合注意力解码

- 将 **KV 按需反量化**与注意力得分计算、在线 Softmax、Value 加权累加融合至解码内核；直接读取压缩编码与分组量化参数，在寄存器中重构 K/V，避免在 HBM 中生成完整的高精度 KV 副本，减少显存读写。
- 在**单张 NVIDIA H100** 上运行 **Llama 2 7B**，相较 Hugging Face 实现取得 **40% 推理加速**。

TileCadence ·FlashAttention-2 共享内存调度 [开源代码]

- 构建**约束求解器**，将释放的共享内存重新分配给概率块、输出分片和 LSE。为 Ampere 和 Blackwell 编译 **CUDA/CuTe** 内核，按资源占用和实测延迟择优。
- 在 **DGX Spark** 上实测 13 个 Qwen3-4B 预填充形状（8K–32K），注意力算子相较默认 FlashAttention-2 达到 **1.11–1.13 倍速度**，输出和 LSE 逐位一致。

其他工程经历

Rtelligent Technology | 软件工程实习生 2021.01 – 2021.05

- 为 ARM Cortex-M 激光雕刻系统开发 C++ 固件；优化 G-code 处理使处理耗时降低 **20%**，利用 Xilinx FPGA 并行处理光栅图像使雕刻速度提升 **30%**。

技术能力

编程与工具：Python、C/C++、CUDA、OpenMP、Verilog、Git、Docker。

大模型系统：PyTorch、Transformers、vLLM、FlashAttention、KV Cache 量化、推测解码。

教学、学术服务与荣誉

中佛罗里达大学：讲师：2026.08–2026.12：数字系统（EEE3342C）、计算机组成（EEL3801C）；2024.08–2025.05：计算机组成实验课程；**助教：**2026.08–2026.12：硬件安全与可信电路设计（EEE4346C）；2025.05–2025.08：Junior Design。

学术服务：ICLR 2027 审稿人。

ORCGS 博士奖学金（2023–2027）；浙江省大学生程序设计竞赛省赛团体三等奖（2019）；杭州电子科技大学学业奖学金（一、二、三等，2017–2020）。